
VAERS: por qué los conteos crudos engañan

Análisis crítico de datos de farmacovigilancia desde la ciencia de datos

Francisco Antonio Ardiles

Analista de datos

Proyecto: Portafolio de ciencia de datos | **Fuente principal:** VAERS (CDC/FDA), año 2021 | **Denominador:** Our World in Data

Repositorio: github.com/franciscoantonioardiles-ctrl/Proyecto-vaers | **Fase documentada:** Notebook 01 — Exploración y perfilado

Naturaleza de este documento

Este informe consolida el trabajo realizado en la fase de exploración del proyecto. Su objetivo no es concluir sobre la seguridad de las vacunas, sino demostrar un principio metodológico: **un mismo dato produce lecturas opuestas según se analice bien o mal**. Documenta las decisiones tomadas, los hallazgos empíricos y las lecciones de ciencia de datos que los sustentan.

1. La pregunta y la tesis

Pregunta de investigación

¿Qué revela VAERS sobre la seguridad de las vacunas cuando se analiza **con denominadores**, y por qué los conteos crudos de reportes llevan a conclusiones falsas?

La tesis del proyecto es de **método**, no de postura. VAERS (Vaccine Adverse Event Reporting System) es un sistema de vigilancia **pasivo**: cualquiera puede enviar un reporte, los reportes no están verificados y, según la propia FDA, para ningún evento reportado se ha establecido relación causa-efecto. Además, los datos públicos no incluyen denominador (dosis administradas). Por ello, un conteo absoluto de reportes es epistemológicamente insuficiente: sin escala ni causalidad, no dice nada sobre riesgo. El proyecto reconstruye ese error de lectura y luego lo corrige.

Nota sobre "fuentes independientes del gobierno"

El marcador de calidad de un dato no es su origen (gubernamental o no), sino su **metodología, trazabilidad, reproducibilidad y la existencia de denominadores y grupos de control**. VAERS es una fuente pública y transparente; su limitación no es política sino de diseño (vigilancia pasiva). Los sistemas de vigilancia activa (Vaccine Safety Datalink, FDA BEST) son metodológicamente más rigurosos precisamente porque tienen cohortes con denominador y comparación.

2. Fuentes de datos y sus limitaciones

El análisis integra dos fuentes con roles complementarios: VAERS aporta el **numerador** (reportes) y Our World in Data el **denominador** (dosis administradas).

Fuente	Contenido	Rol	Limitaciones clave
VAERS (CDC/FDA)	Reportes de eventos adversos posteriores a vacunación	Numerador	Pasivo, no verificado, sin causalidad, sin denominador, subregistro; encoding Latin-1
Our World in Data	Dosis COVID-19 administradas por país y fecha	Denominador	Cobertura temporal no siempre coincide con la de los reportes; CC BY 4.0

Hallazgo documental confirmado en la fuente

El aviso oficial de VAERS confirma el cambio del **8 de mayo de 2025**: los datos públicos ahora incluyen reportes secundarios. Estos **no representan eventos adicionales**, sino registros adicionales de eventos ya notificados. Consecuencia directa: en el archivo aparecen más filas, pero no más casos. Contar filas sin deduplicar por VAERS_ID infla artificialmente el conteo.

3. Flujo de trabajo y decisiones de ingeniería

Antes del análisis se construyó una base reproducible. Cada decisión responde a un principio, no a una preferencia:

- **Estructura del repositorio** (README, DATA_SOURCES, notebooks/, data/, src/): la organización de carpetas es documentación; comunica el diseño antes de leer una línea de código.
- **Separación datos/código vía .gitignore**: los datos crudos (regenerables desde la fuente) no se versionan. Esto respeta el límite de tamaño de GitHub y garantiza reproducibilidad: el análisis se regenera desde el origen autoritativo, no desde una copia.
- **Licencia MIT para el código, licencias propias para los datos**: distinción entre "mi trabajo" y "el dato de terceros" (VAERS es dominio público; OWID es CC BY 4.0).
- **Flujo Colab ↔ GitHub unidireccional**: el notebook se edita ejecutándolo en Colab y se guarda como commit en GitHub. Nunca se edita el .ipynb (JSON) a mano, porque un error de sintaxis lo corrompe.
- **Blindaje de memoria con usecols**: el archivo de datos (663 MB) se carga leyendo solo las 12 columnas del perfilado, no las 35. Cargar lo que no se usa es desperdicio de recursos y, con archivos grandes, la causa típica de reinicio del kernel.
- **Encoding Latin-1 explícito**: los CSV de VAERS no son UTF-8; forzar el encoding evita el UnicodeDecodeError.

4. Hallazgos del perfilado (datos reales, 2021)

4.1 Estructura y grano

El **grano** (qué representa cada fila) define la unidad de análisis. La verificación de unicidad de VAERS_ID arrojó un hallazgo que **refutó empíricamente** el supuesto inicial de que DATA tendría una fila por reporte:

Tabla	Filas	VAERS_ID únicos	Grano observado
DATA	768.706	753.476	NO único — 15.230 filas extra (reportes secundarios)
VAX	813.434	753.476	1:N — un reporte puede tener varias vacunas
SYMPTOMS	1.030.204	753.472	1:N — hasta 5 síntomas por fila

Lección: el conteo se hace sobre VAERS_ID deduplicado, nunca sobre filas crudas

Las tres tablas convergen a **~753.476 reportes únicos**, no a las 768.706 filas de DATA. Los 15.230 duplicados son la huella cuantificada del cambio de mayo 2025. Si se contaran filas como reportes, se sobrestimaría en 15.230 — el mismo error, en miniatura, que el proyecto expone a mayor escala.

4.2 Calidad: tasa de nulos

Las columnas de desenlace grave presentan nulos altísimos. Esto **no** es un defecto de calidad: es estructura semántica. En VAERS son banderas que solo se marcan cuando el evento ocurre y quedan vacías en caso contrario.

Columna	% nulos	Interpretación
DATEDIED	98,7 %	Desenlace (fecha de muerte)
DIED	98,5 %	Desenlace — vacío significa "no marcado", NO "no murió"
L_THREAT	98,4 %	Desenlace (amenaza de vida)
DISABLE	98,3 %	Desenlace (discapacidad)
HOSPITAL	93,4 %	Desenlace (hospitalización)
STATE	15,2 %	Limita análisis geográfico
AGE_YRS	10,7 %	Limita segmentación por edad
ONSET_DATE	8,7 %	Necesaria para alineación temporal
VAX_DATE	7,4 %	Necesaria para alineación temporal
RECVDATE / VAERS_ID / SEX	0,0 %	Campos obligatorios — completos al 100 %

Lección: un nulo no es intercambiable con cero ni con negativo

Que DIED esté 98,5 % vacía significa que la mayoría de reportes no marcaron muerte (los eventos leves dominan), lo cual es epidemiológicamente esperable. El error fatal — en ambas direcciones — nace de malinterpretar ese NaN: ni el vacío prueba seguridad, ni el 1,5 % no vacío prueba daño. Cada columna con nulos altos exige preguntar POR QUÉ está vacía, no aplicar el umbral mecánicamente.

4.3 El numerador COVID-19

Filtrando VAX_TYPE = COVID19 y recuperando los reportes en DATA (deduplicados) se obtiene el numerador. En 2021, COVID domina el conjunto por un factor de ~52x sobre la segunda vacuna, lo que valida empíricamente la elección del año.

VAX_TYPE	Conteo	Descripción
COVID19	757.746	Vacuna COVID-19
VARZOS	14.538	Herpes zóster
UNK	9.611	Desconocida
FLU4	5.469	Influenza
Reportes COVID únicos (numerador)	711.070	94,4 % de los 753.476 reportes de 2021

4.4 El hallazgo central: conteo crudo frente a tasa con denominador

Los conteos crudos son, deliberadamente, los números que circulan mal interpretados. El código contó DIED = 'Y' (no los no-nulos), verificado porque las 10.206 muertes equivalen al ~1,44 % esperado.

Métrica	Valor	Lectura
Reportes COVID-19 totales	711.070	Numerador base
Con DIED = 'Y'	10.206	Muertes reportadas (cualquier causa, sin causalidad)
Con HOSPITAL = 'Y'	46.264	Hospitalizaciones reportadas
Dosis COVID-19 administradas (EE. UU., OWID)	676.728.782	Denominador (acumulado)
Tasa preliminar de reportes por millón de dosis	1.050,7	Lectura con denominador

El corazón del proyecto

El número crudo 711.070 — que en aislamiento suena alarmante — equivale a **~1.051 reportes por millón de dosis (~0,105 %)**. La misma realidad, dos lecturas opuestas. El denominador no prueba seguridad ni peligro: le devuelve la ESCALA al número, sin la cual toda interpretación es imposible. Ese contraste entre "711.070" y "~1.051 por millón, sin causalidad" ES la tesis.

5. Por qué el resultado es preliminar (rigor)

La tasa de 1.050,7 demuestra que el método funciona, pero **no es el resultado final**. Tres sesgos metodológicos, ya identificados, deben resolverse antes de cualquier conclusión:

- **Desalineación temporal:** el numerador es de 2021; el denominador es el acumulado dic-2020 a may-2023. Dividir reportes de un año por dosis de dos años y medio subestima la tasa. Debe recortarse el denominador a las dosis administradas en 2021.
- **Mezcla numerador-denominador:** el numerador son reportes (mayoría eventos leves). Para la tasa de un desenlace específico, el numerador correcto es DIED = 'Y' (10.206) u HOSPITAL = 'Y' (46.264), no el total.
- **Ausencia de causalidad:** ni una tasa perfectamente calculada prueba que la vacuna causó los eventos. VAERS registra correlación temporal; la tasa contextualiza la magnitud del reporte, no establece causa.

6. Próximos pasos (Notebook 02)

El diseño del siguiente notebook se apoya en los parámetros reales obtenidos en esta fase — la razón por la que se perfiló antes de modelar:

- **Alinear ventanas temporales** entre reportes VAERS y dosis administradas.
- **Deduplicar** los reportes secundarios (15.230 filas) por VAERS_ID.
- **Calcular tasas por millón de dosis** por mes y por tipo de evento (muerte, hospitalización).
- **Contrastar formalmente** la lectura cruda frente a la lectura con denominador.

Documento generado como parte de la documentación del proyecto. Los números provienen de la ejecución real del notebook 01 sobre el archivo VAERS 2021. Nada en este análisis establece causalidad; VAERS genera hipótesis, no pruebas.